

FIRST CAPABILITY COMPLETE

LIVE ACCEPTANCE PASSED

第一部分建设成果报告

权威源自动采集与 AI 证据入库

8 个固定权威来源 · AI 标题门禁 · 原文快照 · 全链路溯源

报告日期：2026 年 7 月 29 日

能力状态：第一部分实现、独立审查、确定性测试与实时 8 来源验收均已完成

实时运行 ID：a174ed10-0ef1-4983-b81f-7f8d2bed84d2

部署形态：Python 3.11 + FastAPI + PostgreSQL/pgvector + MinIO + 独立 Scheduler/Worker

相关性规则：ai-title-v1，不依赖大模型即可运行

管理摘要 第一部分已从“网页抓取脚本”升级为可部署、可恢复、可审计的权威证据入口。系统每天可从 8 个固定权威来源扫描近期列表，只对 AI、人工智能、机器人、具身智能、大模型、算力、AI 芯片、脑机接口及相关政策标题请求详情页；无匹配时返回 0 条，不使用无关政策或普通科研文章凑数。每条候选同时保存清洗正文、原文链接和不可变网页快照，可直接供后续 LangGraph 总结/选题节点使用。

1 本阶段建设目标与业务价值

本阶段解决后续 AI 内容生产的事实入口问题。它不负责摘要、选题、文案或生图，而是先回答三个基础问题：**数据来自哪里、是否与 AI 主题相关、未来能否回到原文复核。**

目标	已实现能力	直接价值
固定权威来源	8 个政府、高校、科研机构、企业与权威媒体来源版本化登记	避免模型自由浏览和未知来源污染
只收相关内容	标题相关性规则在详情请求前执行，支持 AI 相关政策	降低无关正文、调用成本和后续人工筛选成本
保存完整证据	清洗正文、原始快照、URL、时间、哈希、解析版本与运行记录	文章修改或下线后仍可审计复现
每天稳定运行	独立调度器、持久 Job、租约、心跳、幂等与失败分类	服务重启后可恢复，单站失败不阻塞其他来源
下游可直接消费	列表提供来源/标题/时间/链接，详情提供正文与快照	后续节点无需重复访问官网

2 来源范围与主题边界

2.1 固定的 8 个来源

级别	来源	类型	主要用途
A	中国政府网最新政策	政府/政策	AI 规划、法规、标准、治理与产业政策支持政策
A	北京师范大学新闻网	高校	AI 教育、人才培养与学校合作的一手信息
A	中国科学院科研进展	科研机构	与 AI/智能系统明确相关的科研进展
A	商汤科技新闻中心	AI 企业	企业一手产品、模型、机器人与产业实践
B	新华网科技	权威媒体	科技趋势、产业背景与事实佐证
B	光明网教育	权威教育媒体	AI 教育、机器人赛事和学校实践
B	科技日报	科技媒体	AI、具身智能、算力与科技产业动态
B	中国新闻网教育	权威教育媒体	AI 教育现象、治理问题与社会观察


2.2 AI 标题门禁

规则版本 ai-title-v1 使用 Unicode NFKC、大小写折叠、空白与短横线归一化，覆盖 AI/人工智能、AIGC、大模型、GPT/ChatGPT/DeepSeek、机器学习、算法、算力、AI 芯片、计算机视觉、语音/NLP、机器人、具身智能、自动驾驶、无人机和脑机接口等主题。

政策词“规划、办法、标准、治理、通知、支持”等不能单独使文章通过；只有标题同时出现明确的 AI/智能技术词时，才作为 AI 政策接受。系统同时拒绝 Travel agents、Chemical agent、商业信心指数 BCI、招生语境 UAS、智能体检、智能体育等歧义写法。

保守原则 宁可暂时漏掉标题没有明确 AI 信号的文章，也不抓取无关内容。新术语通过发布新的相关性规则和来源版本扩展，不能原地修改历史规则。

3 系统实现与数据流



1. 列表响应先经过允许域名、公共 IP、重定向、类型、字节与超时安全检查；
2. 连接器扫描有限的近期列表，合并图片空链接与文本链接，形成有序候选；
3. 标题门禁过滤无关项，只有相关项才发起详情请求；
4. 原始列表和相关详情以内容哈希写入 MinIO，不同字节不能覆盖同一对象；
5. PostgreSQL 保存来源版本、运行、Job、候选、Observation、计数与快照引用；
6. 后续节点通过 candidate ID 获取已保存正文，不把原文链接当作新的自由爬虫入口。

42026-07-29 实时验收结果

4.1 总体运行指标

指标	结果	指标	结果
Run ID	a174ed10-0ef1-4983 b81f-7f8d2bed84d2	规则版本	ai-title-v1
来源任务	8/8 成功	失败任务	0
新增相关候选	6	无相关内容来源	2
过滤无关标题	263	重复/未变化	0/0
任务执行窗口	约 7.5 秒	本轮响应字节	993,007 Bytes
未完成 Job	0	抓取租约	0

本轮中国政府网扫描 100 条政策、中国科学院扫描 15 条科研进展，均未发现标题明确关联 AI 或智能科技的内容，因此两个 Job 以 no_relevant_items 成功结束，没有抓取无关详情页。这比“每站强行返回一条”更符合证据质量目标。

4.2 各来源过滤与接受情况

来源	结果	过滤数	入库数
北京师范大学新闻网	成功	22	1
中国科学院科研进展	无相关内容	15	0
中国政府网最新政策	无相关内容	100	0
中国新闻网教育	成功	57	1
光明网教育	成功	36	1
商汤科技新闻中心	成功	5	1
科技日报	成功	7	1
新华网科技	成功	21	1

4.3 正式入库的 6 条相关内容

来源	标题/原文	发布时间	命中词	正文字符
北京师范大学	北京师范大学与北京航空航天大学签署关于人工智能 + 教育领域的合作框架协议 查看原文	07-19 16:37	人工智能	1,670
中国新闻网	AI 研学营，“注水”很普遍 查看原文	07-14 13:21	AI	4,112
光明网	首届北京市中学生人形机器人足球赛总决赛举行 查看原文	07-23	机器人	1,690

来源	标题/原文	发布时间	命中词	正文字符
商汤科技	全球首个端侧驱动本体的具身世界模型！大晓机器人发布 Kairos 3.1 查看原文	07-28	人工智能、AI、机器人	3,991
科技日报	全国首个具身智能发展局揭牌 查看原文	07-29 10:08	具身智能	607
新华网	AI 奢护新范式 查看原文	07-24	AI	87

上述 6 条候选均保存了清洗正文和详情快照。详情快照合计 309,371 Bytes；本轮列表与详情网络响应合计 993,007 Bytes。标题命中词与规则版本已写入候选提取元数据，后续可解释“为什么这篇文章被接受”。

5 质量、安全与独立审查

5.1 最终质量门

检查	结果
后端自动化测试	112 项全部通过，总覆盖率 86%，标题相关性模块覆盖率 100%
代码质量	Ruff 格式/lint 通过；strict mypy 检查 46 个源文件通过
真实服务集成	PostgreSQL、MinIO、迁移、快照、幂等、租约、重试与无关详情阻断通过
前端合同	OpenAPI 漂移检查、Prettier、ESLint、TypeScript、Vitest 3/3、生产构建通过
运行环境	Doctor、pgvector 0.8.1、Alembic 20260729_0003、MinIO Bucket 通过
交付检查	Compose 渲染、Shell 语法、git diff --check、项目凭据正则扫描通过

5.2 独立审查发现并修复的问题

- 收紧 agent、BCI、UAS 等英文歧义，补充 DeepSeek、ChatGPT、GPT、chatbot、intelligent system 与 Unicode 短横线形式；
- 防止“深度学习”在普通教育语境误收，防止“智能体检、智能体育、智能体系”等复合词误收；
- 数据库降级前恢复旧活动来源版本，避免旧 Worker 将新版本误判为无过滤版本；
- 修复重试时过滤计数重复累加，终态只保存一次扫描值；
- 详情页第一次请求也执行单来源限速，避免列表请求后立即连续访问。

5.3 安全边界

系统只允许来源登记表中的 HTTPS 域名和路径，逐次校验 DNS 与重定向目标，拒绝私网、环回、链路本地、元数据和 Fake-IP/基准地址。响应设置连接/读取/总超时、最大字节、内容类型和单来源速率。日志不记录完整正文、Cookie、授权头或签名 URL。抓取 Worker 已在验收后停止，当前未完成任务和来源租约均为 0。

6 当前边界与下一阶段建议

6.1 当前明确边界

- 当前只抓取 8 个已审核来源，不做全网搜索，也不接受任意 URL；
- 当前规则为确定性标题门禁，可能有意漏掉标题没有明确 AI 信号的新术语；
- 当前交付为服务器可部署形态，正式主机的域名/TLS、认证、备份和外部监控另行建设；
- 本阶段不做摘要、聚类、选题评分、文案生成、生图或自动发布；
- Docker 镜像在正常网络带宽下的完整构建和 gitleaks 工具扫描仍属于部署工具跟进项。

6.2 下一阶段：LangGraph 工作流

建议下一阶段使用 LangGraph 编排需要状态和分支的 AI 工作流，但不替代本阶段的调度器、Worker、数据库租约和安全抓取。建议节点为：



LangGraph 节点使用 candidate ID 读取已保存正文和快照；原文链接用于引用与人工核验，不在每个节点重新访问官网。这样模型服务不可用或工作流重试时，也不会重复抓取权威网站。

阶段结论 第一部分已经形成可信、可持续的事实输入边界：来源固定、主题可解释、无关内容可拒绝、正文与原始网页可追溯、失败和重试可恢复。系统已具备进入第二部分“数据治理、摘要与选题”建设的前提条件。