

技术路线与系统架构设计方案

面向家长的每日自动 AI 教育内容 Agent

权威证据采集 · 智能选题 · 品牌知识增强 · 可审计内容生成

项目目标：每天从可治理的权威来源自动形成候选证据池，筛选最值得家长关注的 AI 与科学教育话题，并生成可核验、符合赛先生品牌口径的图文素材包。

建设顺序：先建立稳定、可追溯的权威源自动采集能力，再依次建设数据治理、自动选题、品牌检索、生成审校与素材交付。

安全边界：系统只提供审核、复制、下载与原始来源查看，不保存社交平台凭据，不自动发布朋友圈。

部署基线：Ubuntu + Docker Compose；Python 3.11、FastAPI、PostgreSQL/pgvector、MinIO、React/TypeScript/Vite；模型能力由公司 AI 平台提供。

文档版本：v0.3 · 权威证据优先的能力建设路线

核心定位 系统不是“让模型自由寻找并讲述新闻”，而是先建立受治理的证据输入，再让选题与生成能力在证据边界内工作。每一条可外部核验的核心事实都必须回到保存的原始来源；品牌知识负责表达方式，不能替代事实依据。

1 项目背景与建设目标

销售团队向家长持续传递科学教育、AI 政策与科技前沿内容时，传统人工模式存在三类长期问题：**选题投入高、权威事实难持续核验、品牌表达不稳定**。如果直接从“模型生成”开始，短期可以得到演示结果，却无法证明信息是否完整、来源是否可靠、后续能否自动运行。

因此，本系统采用“**权威证据优先**”的建设原则：先让来源、采集、快照与溯源形成稳定底座，再逐层增加数据治理、评分选择、品牌知识与生成能力。系统的最终输出是可供销售人员人工审核与使用的“每日素材包”，而不是自动发布工具。

设计原则	具体含义	对系统的约束
证据先于生成	先保存可复查的原始来源，再进入摘要、评分与写作	模型记忆不能作为事实来源
证据与品牌分离	事实语料回答“发生了什么”，品牌语料回答“如何表达”	品牌文档不能证明新闻或政策事实
确定性校验优先	Schema、证据覆盖、禁用词、日期与隐私规则先执行	LLM 审校不能覆盖硬性失败
持久状态与幂等	每次任务、尝试、输入和产物都可以恢复与追踪	重试不能重复产生外部副作用
人工在环	素材包用于审核、复制和下载	不提供自动社交发布能力

2 目标架构与端到端 workflow

系统由十个连续能力节点组成。第一节点“权威源自动采集”是建设起点，也是后续所有模型能力的事实入口。



系统边界 调度器负责产生持久任务，Worker 负责执行采集与模型调用，API 负责短事务与状态查询，PostgreSQL 是运行状态和证据关系的事实来源。任何抓取文本和模型输出都视为不可信数据；销售团队仍负责最终审核与手动分发。

3 建设第一步：权威源自动采集与证据入库

3.1 目标、输出与明确边界

第一步不以“抓到若干网页”为完成标准，而是建立一个可持续运行、可追踪失败、可复查原文的证据入口。它的输出是**可查询、可审计的候选证据池**，供下一步清洗、去重、事件聚类与分类使用。

范畴	本步骤负责	本步骤不负责
来源	登记、分级、启停、抓取策略、责任归属	自动判断未知网站是否权威
采集	定时增量获取、原始响应保存、正文解析、失败分类	选题评分与内容生成
证据	保存 URL、时间、来源、原文快照和版本信息	用品牌材料替代外部事实
模型	无强依赖；采集链路可在无模型服务时运行	LLM 摘要、语义分类、写作和生图


3.2 版本化来源登记表

所有采集目标先进入来源登记表，由业务与技术共同审核后启用。代码中不散落临时 URL；每个连接器都必须绑定稳定的 `source_id` 和来源版本。

来源级别	典型来源	使用规则
一级：主要证据	政府与教育主管部门、学校/高校、研究机构、国际组织、企业一手公告	可作为事实证据；重要或含歧义信息应尽量交叉核验
二级：可信背景	具名记者与清晰引用链的教育、科技、科学媒体	用于发现、背景或佐证；存在一手来源时优先回溯
三级：线索来源	社交平台、转载号、匿名账号、来源不明聚合站	仅发现话题，不得直接支撑最终事实声明

来源登记至少包含：来源名称与组织类型、可信级别、允许域名、抓取方式（RSS、API 或 HTML）、栏目入口、采集频率、时区/语言、启用状态、维护人、条款与 robots 复核记录、连接器和解析器版本。

3.3 采集执行架构



- 独立调度：**调度器以独立进程运行，按来源和业务时区创建持久采集任务；数据库租约或唯一业务键避免多个实例重复入队。
- 协议优先级：**优先使用 RSS 与公开 API；仅对审核过的允许域名启用 HTML 解析，并使用 `httpx`、`trafilatura` 与 `BeautifulSoup` 等适配器。
- 增量采集：**使用来源文章 ID、发布时间窗口、分页游标以及可用的 ETag / Last-Modified，减少重复请求并提升新鲜度。
- 先快照后转换：**在清洗和摘要前保存原始响应或规范化快照；后续派生数据必须引用快照 ID 与解析版本。
- 幂等写入：**以来源文章 ID、规范 URL 与内容 SHA-256 形成多层身份；重复记录保留来源关系，不直接抹除证据历史。

3.4 抓取安全、韧性与失败治理

权威来源意味着事实可信度更高，不代表网页内容或网络地址天然安全。抓取器必须将页面文本视为数据，忽略其中任何试图改变系统行为的指令。

控制面	最低要求
网络边界	仅允许登记域名与 HTTPS；解析并阻断环回、私网、链路本地和云元数据地址，限制重定向次数
资源边界	设置连接/读取/总超时、最大响应字节、允许内容类型、并发与单来源速率
重试策略	仅对超时、限流和临时服务异常执行有上限的指数退避；解析失败与权限拒绝不盲目重试
合规与礼貌	记录 robots/条款复核结果，使用可识别 User-Agent，尊重频率限制，不绕过登录、验证码或访问控制
内容安全	不把页面指令拼接为系统提示；日志不记录完整正文、Cookie、授权头或敏感个人信息

3.5 采集与证据数据契约

字段组	关键字段	说明
身份与运行	source_id, acquisition_run_id, item_id	关联来源版本、一次持久运行和来源侧文章身份
位置与归属	original_url, canonical_url, source_tier	保存原始入口、规范地址、来源组织与可信级别
时间	published_at, fetched_at, source_timezone	发布时间允许缺失但必须显式标记；抓取时间以 UTC 存储
原始快照	snapshot_uri, content_type, byte_size	快照放在受控对象存储；数据库保存引用、类型与大小
内容身份	content_sha256, etag, last_modified	支持精确重复识别、条件请求和审计复现
解析版本	connector_version, parser_version, normalization_version	解析规则变化后可以重放并解释差异
派生正文	title, clean_text, language	作为候选证据；不能替代原始快照
执行结果	status, error_code, attempt, request_id	区分成功、未变化、暂时失败、永久失败与解析失败

3.6 第一步完成标准

可验收结果

- 选取覆盖政策、教育机构、科研/国际组织与企业一手发布的代表性来源，完成来源登记与连接器验证；
- 定时任务能够形成持久运行记录，并对重复执行保持幂等；
- 每条成功候选均可回到原始 URL、来源身份、发布时间、抓取时间和不可变快照；
- 超时、限流、无权限、格式变化、超大响应、重定向异常与重复内容均有可测试的安全结果；
- 可按来源查看成功率、最新成功时间、新增数量、解析失败率、重复率、耗时和重试次数；
- 在公司模型平台不可用时，权威源采集和证据入库仍可独立运行。

4 后续能力模块设计

4.1 数据治理、去重与事件组织

在原始快照之上执行 URL 规范化、正文清洗、时间统一与来源身份归一。使用规范 URL、来源文章 ID 与正文 SHA-256 进行精确重复识别；随后使用 SimHash、Embedding 相似度和事件聚类识别同一事件的多篇报道。重复数据保留指向原始来源的关系，不能因去重丢失溯源。

结构化分类输出版本化标签，例如 **policy**（政策）、**frontier**（前沿）、**case**（学校/课堂案例）、**safety**（AI 安全与隐私）。社交线索在回溯到合格事实来源前保持不可入选状态。

4.2 自动选题、硬性否决与无题熔断

评分配置声明特征范围、权重、惩罚、版本和稳定的并列规则：

$$\begin{aligned} \text{选题总分} = & \text{来源可信度} + \text{AI/科学教育相关度} + \text{家长关联度} + \text{新鲜度} \\ & + \text{传播价值} - \text{历史重复度} - \text{争议/营销风险} \end{aligned}$$

未核实线索、未成年人隐私风险、重大法律/安全不确定性、不适合品牌传播的负面事件及七天内重复事件属于硬性否决，不能被高分抵消。只有合格候选达到阈值时才锁定当日话题；否则运行状态为 **no_topic**，当天不强行生成。

4.3 品牌知识库与双域检索

系统维护两个独立语料域：

1. **事实证据域**：来源快照、候选文章、事件聚类与证据段落，用于证明外部事实；
2. **品牌知识域**：品牌理念、家长沟通原则、安全规则、禁用表达、优质案例和视觉规范，用于约束表达。

品牌知识按版本、受众和有效期管理。初始混合检索使用 PostgreSQL 全文排序与 **pgvector** 语义检索，通过可测试的结果融合和重排序选出有限上下文。若未来选择其他全文检索扩展或服务，应另行记录架构决策。

4.4 结构化文案与声明—证据绑定

文案 Agent 只接收明确分隔的事实证据与品牌上下文，并输出可由 Pydantic v2 校验的结构：

```
{
  "copywriting": "面向家长的朋友圈正文",
  "parent_takeaway": "与孩子和家庭相关的认知点",
  "interaction": "自然、不过度营销的互动引导",
  "source_note": "面向读者的来源说明",
  "image_prompt": "符合品牌视觉规范的生图提示",
  "claims": [
    {
      "id": "claim_01",
      "text": "可外部核验的核心事实",
      "kind": "external_fact",
      "evidence_ids": ["evidence_01"]
    }
  ]
}
```

每个 `external_fact` 声明至少绑定一条合格证据，绑定关系保留原始 URL、来源级别、发布时间和支持段落。面向读者的 `source_note` 用于展示，不能替代机器可验证的证据关系。

4.5 确定性校验、LLM 审校与有限重试

质量控制按固定顺序执行：

1. **确定性校验**：Schema、必填字段、证据覆盖、来源级别、URL、日期、长度、禁用词、隐私、重复话题和图片规则；
2. **LLM 风险审校**：判断隐含夸大、焦虑制造、品牌适配、家长价值与图像风险，返回问题代码和对应声明 ID；
3. **有限重试**：只把结构化问题反馈给生成阶段，并限制次数；耗尽后保留草稿与问题，进入可审查失败状态。

审校模型不是独立事实来源，不能凭自身记忆补齐缺失证据，也不能覆盖硬性否决。

4.6 视觉生成与每日素材包

只有通过校验和审校的图片提示才进入公司 AI 平台的图像能力。图片采用温暖、明亮、可信的中国家庭科学教育插画方向，避免复杂中文文字、夸张科幻感、真实未成年人身份特征和潜在侵权元素。请求指纹、模型/提示版本、尝试次数、提供方请求 ID 与对象存储状态均需保存，确保重试不重复生成。

内部页面展示话题、生成日期、朋友圈正文、家长洞察、互动建议、图片、原始来源、声明证据和校验/审校状态，并提供键盘可操作的复制和下载。系统不出现“自动发布”按钮或社交平台凭据入口。

5 技术栈、运行职责与部署

架构层次	技术选型与责任
基础设施与部署	Ubuntu、Docker Compose；本地/私有环境使用 PostgreSQL/pgvector 与 MinIO，基础设施仅绑定受控网络接口
API 服务	Python 3.11、FastAPI、Pydantic v2；负责输入校验、短数据库事务、运行/素材包状态查询和 OpenAPI 合约
调度器	独立进程；按 Asia/Shanghai 业务日期创建持久任务，通过数据库租约或唯一键避免重复调度
Worker	执行采集、解析、Embedding、LLM 与图片等长任务；使用租约、心跳、幂等键和有界重试
数据与检索	PostgreSQL、SQLAlchemy 2 async、Alembic、pgvector；分别管理事实证据域与品牌知识域
对象存储	MinIO / 公司 S3 兼容对象存储；保存受控原始快照、生成图片和可审计产物
模型能力	公司 AI 平台提供 LLM、Embedding 与图像能力；通过能力适配器隔离具体请求格式
前端交互	React、TypeScript strict、Vite、TanStack Query；OpenAPI 生成接口类型，提供内部审核与复用工作台

状态与可恢复性 数据库是运行和阶段状态的事实来源。每个持久任务记录输入版本、幂等键、尝试次数、租约、错误分类和产物引用。第一步可使用 PostgreSQL 任务认领机制；只有在吞吐量和运维需求被验证后，才考虑引入独立队列基础设施。

6 按能力交付的建设路线

项目不使用抽象等级标签，而是按可独立验收的能力顺序推进。每一步都建立在前一步的持久数据契约之上。

顺序	建设能力	核心交付	完成证据
第一步	权威源自动采集与证据入库	来源登记、独立调度、RSS/API/HTML 连接器、安全抓取、原始快照、幂等记录与监控	代表性来源稳定增量入库，成功与失败均可追踪并回到原文
第二步	数据治理与事件组织	正文规范化、精确/近似去重、来源关联、事件聚类与结构化分类	重复不丢溯源，同一事件可聚合，多次处理结果稳定
第三步	选题资格、评分与锁定	硬性否决、版本化特征/权重、阈值、七天重复规则、no_topic	标注样本集可解释评估，无合格话题时停止生成
第四步	品牌知识与双域检索	品牌文档版本化、切块与元数据；事实/品牌分离检索；全文与向量结果融合	检索结果可解释，品牌材料不能被用作外部事实证据
第五步	证据绑定生成与质量门	结构化声明、证据绑定、确定性校验、LLM 风险审校、有限重试	无证据事实无法通过；审校失败保留问题与产物

顺序	建设能力	核心交付	完成证据
第六步	视觉生成与素材交付	审核后生图、对象存储、素材包 API、内部审核/复制/下载页面	完整素材包可人工复核和使用，系统不存在自动发布路径

7 质量门、风险与持续治理

7.1 跨层质量门

- **后端**：格式与 lint、严格类型检查、单元/集成测试、真实 PostgreSQL/pgvector 行为、迁移升级、采集安全和幂等测试；
- **前端**：格式与 lint、TypeScript strict、生成接口漂移检查、组件测试、无障碍检查与素材复制/下载流程；
- **跨层**：FastAPI OpenAPI 生成前端类型，CI 在生成结果漂移时失败；
- **安全**：验证线索来源不能成为事实证据、网页指令只能作为数据、日志隐去敏感内容、系统没有自动发布端点。

7.2 关键风险与控制策略

风险	控制策略
权威网站结构变化	连接器/解析器版本化，保存原始快照，监控解析成功率和字段缺失，支持按快照重放
来源中断或限流	单来源限速、有界退避、健康状态与告警；不因一个来源失败阻断全部采集
事实看似可信但缺乏支撑	核心声明绑定到证据段落；高影响或歧义事实优先多源核验
模型幻觉或焦虑营销	确定性证据覆盖与禁用规则先行，LLM 审校只判断表达和含义，不补造事实
外部调用重复计费	请求指纹、阶段幂等键、提供方请求 ID 与产物状态共同约束重试
自动化越过人工边界	API、前端与配置中均不提供社交发布能力或凭据路径

结论 本路线将“自动采集”从一个功能模块提升为整个系统的第一项可验收能力：来源先被治理，证据先被保存，后续评分、检索和生成才有稳定边界。这样既能尽早获得真实数据，又避免在事实底座尚未建立时先投入不可复用的生成演示。