

技术路线与系统架构设计方案

面向家长的每日自动 AI 教育内容 Agent

端到端自动采集、智能选题、品牌 RAG 与多 Agent 审校生成系统

项目目标：构建“每日自动内容 Agent”，系统全自动抓取可信热点、智能打分筛选 Top 1 话题、检索品牌知识库，并生成符合赛先生品牌口径的图文素材包，供销售人员一键复制使用。

核心特点：全链路自动化触发，销售无须人工挑选热点；系统不直接调用 API 自动发布朋友圈，保留“人工在环”安全防线。

部署环境：公司云服务器（Ubuntu + Docker Compose）；通过公司 AI 平台调用 LLM、Embedding 与 GPT Image 2。

文档版本：v0.2 每日自动内容 Agent 架构设计

核心定位：以“无人值守自动选题 + 品牌知识增强 RAG + 多 Agent 事实审校”为核心机制。每日早间自动生成包含朋友圈文案、家长洞察、配图及原始溯源链接的“每日素材包”，大幅降低销售内容运营门槛并保证品牌表达一致性。


1 项目背景与建设目标

销售团队向家长传递科学教育、AI 政策及科技前沿内容时，传统人工模式存在三大痛点：**选题耗时高**、**权威事实难把控**以及**品牌表达易走样**。

本方案旨在打造一个“每日自动内容 Agent”：系统每天定时抓取权威热点，通过自动选题打分引擎选出当天的最佳话题，结合品牌知识库生成高质量文案与配图，最终形成销售可直接使用的标准素材包。

2 目标架构与端到端 workflow

系统逻辑包含“采集—清洗去重—选题打分—品牌 RAG—文案生成—安全审校—视觉生成—素材交付”8 大环节。



3 系统功能模块详细设计

3.1 自动采集模块 (Automated Ingestion)

系统每天早间由定时任务触发，自动抓取可信渠道的热点信息。

- **数据来源:** 教育部、中国政府网、地方教育部门官微/官网；学校、研究机构、国际教育组织；AI 与机器人企业一手发布；权威科技媒体。
- **边界控制:** 抖音、小红书、视频号仅作为 ** 热点线索发现源 **，不直接作为最终事实依据。
- **技术实现:** 使用 APScheduler / Cron 触发任务；RSS/公开 API 优先,辅以 requests + trafilatura / BeautifulSoup 进行正文解析；存入 PostgreSQL。

存储字段名	字段说明与格式要求
title & content	提取的核心标题与解析后的网页干净正文文本
summary & url	自动生成的正文摘要及原始访问 URL 链接（用于后续溯源）
source & dates	信息发布来源名称、官方发布时间及系统抓取入库时间

3.2 清洗、去重与结构化分类

原始数据经过广告与无关文本过滤后，进行多级去重与标签分类：

1. **精确去重:** 基于正文计算 SHA-256 哈希值，直接过滤完全重复的内容。
2. **语义去重:** 利用 Embedding 相似度与 SimHash 识别不同媒体对同一事件的转载报道。
3. **LLM 结构化打标:** 输出固定 JSON 标签: policy (政策)、frontier (前沿)、case (中小学案例)、safety (AI 安全与隐私)、social (社媒线索)。

3.3 自动选题 Agent 与打分模型

替代人工挑选，系统通过多维度打分模型自动评估每条热点的综合价值：

$$\begin{aligned} \text{选题总分} = & \text{来源可信度} + \text{AI/科学教育相关度} + \text{家长视角关联度} + \text{新鲜度} \\ & + \text{传播潜力} - \text{历史重复度} - \text{争议/营销风险} \end{aligned}$$

- **Top 1 锁定**：每日选取综合评分最高的一条热点作为当日核心选题。
- **兜底与熔断机制**：若最高分未达到设定阈值，当天 ** 不强行生成 **；同类主题 7 天内硬性去重；负面事故或未证实传言直接过滤。

3.4 赛先生品牌知识库建设

为了让生成内容符合品牌“赛先生”的口径，知识库专门沉淀：

- 科学教育与 AI 教育的核心理念及品牌表达规范；
- 未成年人隐私、AI 安全合规边界及禁用词/不可夸张承诺清单；
- 历史优质朋友圈文案案例与品牌视觉 Prompt 规则。

知识切块后添加元数据标签，通过 Embedding 存储至 PostgreSQL + pgvector。

3.5 混合检索 RAG (Hybrid Retrieval)

在锁定 Top 1 热点后，系统并不直接调用 LLM 写作，而是发起混合检索：

1. **元数据过滤**：限制条件为“面向家长”且“当前有效”的品牌知识；
2. **关键词与向量混合检索**：组合 BM25 全文检索（政策/术语）与 pgvector 语义相似度检索；
3. **重排序 (Rerank)**：筛选出 Top 3-5 条最相关的品牌知识，随热点事实一同送入文案 Agent。

3.6 文案 Agent 与 Schema 输出

文案 Agent 严格基于“热点事实 + 品牌知识 + 家长向写作规范”进行创作，输出固定 JSON 格式：

```
{
  "copywriting": "朋友圈正文（通俗易懂，讲清与孩子的关系，不制造焦虑）",
  "parent_takeaway": "这件事与孩子的核心关系/家长认知点",
  "interaction": "适合销售与家长互动引导的一句话",
  "source_note": "权威信息来源备注",
  "image_prompt": "注入赛先生品牌视觉规范的 GPT Image 2 生图 Prompt"
}
```

3.7 事实与品牌安全审校 Agent

生成后的草稿必须通过审校 Agent 的质量防线：

- **事实核查**：检查核心事实是否均有原始来源支撑，防止 LLM 幻觉；
- **品牌与风险检视**：严查是否存在夸大营销、焦虑制造、绝对化承诺及未成年人隐私风险；
- **打回重试机制**：若审校不通过，附带错误反馈打回文案 Agent 重新生成；连续失败则标记异常，中断推送。

3.8 GPT Image 2 视觉生成模块

通过公司 AI 平台调用 GPT Image 2，生图 Prompt 会自动叠加赛先生视觉规范：

- **视觉风格：**面向中国家长的科学教育插画，温暖、明亮、可信；
- **主色调与构图：**蓝绿色品牌主色，儿童探索科学/AI 的自然场景，构图简洁保留留白；
- **合规隔离：**避开复杂中文文字渲染、夸张科幻感及潜在合规风险元素。

图片生成后保存至对象存储（MinIO/S3），获取静态 URL。

3.9 每日素材包交付与销售使用

系统最终将生成物打组成“每日素材包”展示于前端页面：包含 ** 热点标题、朋友圈正文、高精配图、原始溯源链接及生成日期 **。销售人员仅需一键复制文案、下载图片，手动发布朋友圈即可。

4 技术栈与架构部署

架构层次	技术选型与组件说明
基础设施 & 部署	公司云服务器（Ubuntu）、Docker Compose 容器化编排
后端服务 & 调度	Python 3.10+、FastAPI、Pydantic、APScheduler / Cron 定时任务
数据存储 & 向量	PostgreSQL + pgvector（存储热点、知识库及向量索引）
对象存储 & 异步	MinIO / 公司对象存储；（扩展阶段引入 Celery + Redis）
模型能力集成	公司 AI 平台 API（调用 LLM、Embedding 与 GPT Image 2）
前端交互	React 构建内部单页应用（MVP 阶段提供极简抓取与展示页面）

5 敏捷实施路线图（Milestones）

项目采取“先验证端到端生成，再逐步增强自动化与审校能力”的敏捷演进策略：

阶段	核心目标	交付功能与边界
P0 阶段	端到端通路验证	完成“人工输入热点 → 文案 Agent 生成 → GPT Image 2 生图”基础链路。
P1 阶段	自动化采集与治理	搭建定点源采集器，实现正文解析、SHA-256 去重与基础分类打标。
P2 阶段	自动选题 Agent	引入多维评分模型与阈值熔断规则，实现每日无人值守选出 Top 1 热点。
P3 阶段	品牌 RAG 增强	建设计划向量知识库，上线混合检索（BM25 + Vector），实现引用溯源。
P4 阶段	质检与反馈闭环	上线审校 Agent、自动重试机制与销售使用反馈逻辑，持续优化生成质量。